SCRAPING

1. Objectif:

L'objectif de cette tâche était de scraper les données du site <u>Books to Scrape</u>. Les données à extraire comprenaient :

- Le titre du livre
- Le prix
- La catégorie
- La disponibilité
- La note (étoiles)
- Le lien du produit
- La description (optionnel)

2. Méthodologie:

Outils utilisés:

- **Python**: Langage de programmation principal.
- Bibliothèques Python:
 - o requests : Pour envoyer des requêtes HTTP et récupérer le contenu des pages.
 - o BeautifulSoup: Pour parser le HTML et extraire les données.
 - o CSV: Pour sauvegarder les données dans un fichier CSV.

• Structure du site:

 Les livres sont répartis sur 50 pages, chaque page contenant environ 20 livres.

Approche:

1. Inspection du site:

a. Inspection la structure HTML et identification les balises et classes CSS contenant les informations nécessaires.

2. Scraping des données :

- a. Extraction des données pour chaque livre sur chaque page.
- b. Gestion de la pagination pour parcourir les 50 pages du site.

3. Structuration des données :

a. Les données extraites ont été sauvegardées dans un fichier CSV
 (livres.csv) pour faciliter leur utilisation dans les étapes suivantes.

3. Code utilisé:

Voici le code Python utilisé pour scraper les données :

```
import requests
from bs4 import BeautifulSoup
import csv
# URL de base du site
base url = "http://books.toscrape.com/catalogue/page-{}.html"
# Fonction pour extraire les données d'une page
def scrape page(url):
    response = requests.get(url)
    soup = BeautifulSoup(response.content, "html.parser")
    books = soup.find_all("article", class_="product_pod")
    page data = []
    for book in books:
        # Titre
        title = book.h3.a["title"]
        # Prix
        price = book.find("p", class_="price_color").text.strip()
        # Catégorie (à extraire depuis la page du produit)
        product link = "http://books.toscrape.com/catalogue/" +
book.h3.a["href"]
        category = get_category(product_link)
        # Disponibilité
        availability = book.find("p", class ="instock
availability").text.strip()
        # Note (étoiles)
        rating = book.find("p", class ="star-rating")["class"][1] #
Exemple : "Three" pour 3 étoiles
        # Lien du produit
        product link = "http://books.toscrape.com/catalogue/" +
book.h3.a["href"]
```

```
# Description (optionnel, à extraire depuis la page du
produit)
        description = get description(product link)
        # Ajouter les données à la liste
        page_data.append({
            "titre": title,
            "prix": price,
            "categorie": category,
            "disponibilite": availability,
            "note": rating,
            "lien": product link,
            "description": description
        })
    return page data
# Fonction pour extraire la catégorie depuis la page du produit
def get_category(product url):
    response = requests.get(product url)
    soup = BeautifulSoup(response.content, "html.parser")
    category = soup.find("ul",
class ="breadcrumb").find all("a")[2].text.strip()
    return category
# Fonction pour extraire la description depuis la page du produit
def get description(product url):
    response = requests.get(product url)
    soup = BeautifulSoup(response.content, "html.parser")
    description = soup.find("meta", attrs={"name":
"description"})["content"].strip()
    return description
# Fonction principale pour scraper toutes les pages
def scrape_books_to_scrape():
    all books data = []
    for page in range(1, 51): # Il y a 50 pages au total
        print(f"Scraping de la page {page}...")
        url = base url.format(page)
        page data = scrape page(url)
        all books data.extend(page data)
```

```
return all_books_data

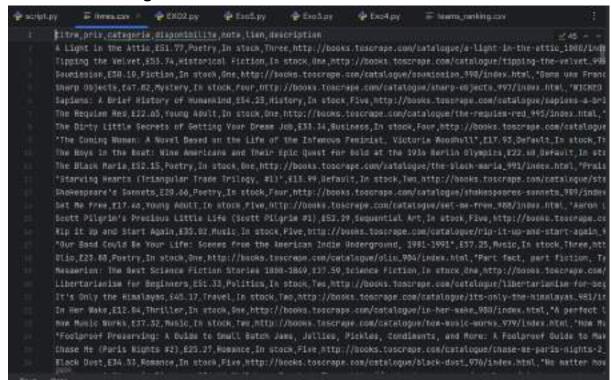
# Scraper les données
data = scrape_books_to_scrape()

# Sauvegarder les données dans un fichier CSV
with open("livres.csv", "w", newline="", encoding="utf-8") as file:
    writer = csv.DictWriter(file, fieldnames=["titre", "prix",
"categorie", "disponibilite", "note", "lien", "description"])
    writer.writeheader()
    writer.writerows(data)

print("Scraping terminé. Les données ont été sauvegardées dans
'livres.csv'.")
```

4. Résultats obtenus :

• Fichier CSV généré: livres.csv

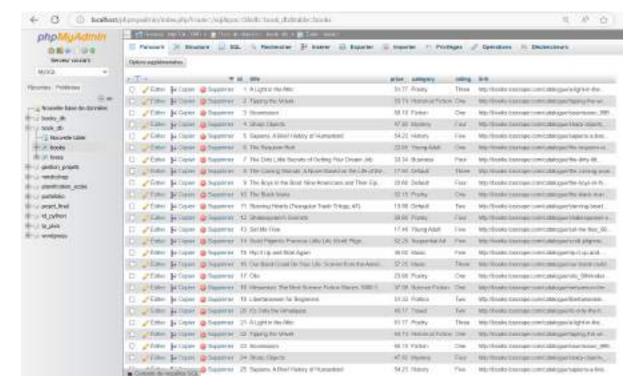


Stockage des données dans une base de données MySQL

```
"C:\Users\kanou\PythonProject1\ Projet_Python\.veru\Script*\python.exe" "C:\Users\kanou\PythonProjec
Extraction des données de : http://books.tuscrape.com/cataloque/page-1.html
Extraction des données de : http://books.tuscrape.com/cataloque/page-11.html
Extraction des données de : http://books.tuscrape.com/cataloque/page-12.html
Extraction des données de : http://books.tuscrape.com/cataloque/page-13.html
```

Dans phpMyAdmin

Insertion des données dans la base



Explication de la base de données

Documentation du Script d'Importation de Livres

Structure de la Table "books"

La table **books** contient les informations suivantes:

- **id** (INT, clé primaire, auto-incrémentée)

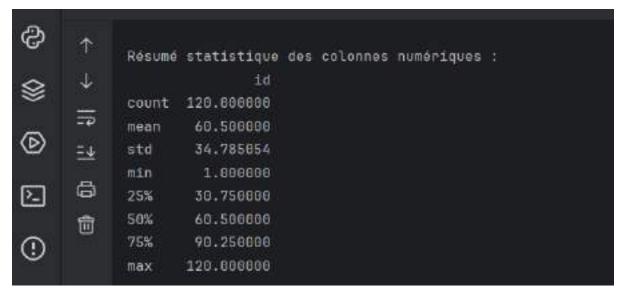
- **titre** (VARCHAR 255, non nul)
- **prix** (DECIMAL 10,2, non nul)
- **categorie** (VARCHAR 100, non nul)
- **disponibilite** (VARCHAR 50, non nul, valeurs possibles : "En stock", "Rupture de stock")
- **note** (INT, non nul, valeur comprise entre 1 et 5)
- **lien** (TEXT, non nul)
- **description** (TEXT, optionnel)
- **moyenne_avis** (DECIMAL 10,2, optionnel, représente la moyenne des notes des livres importés)

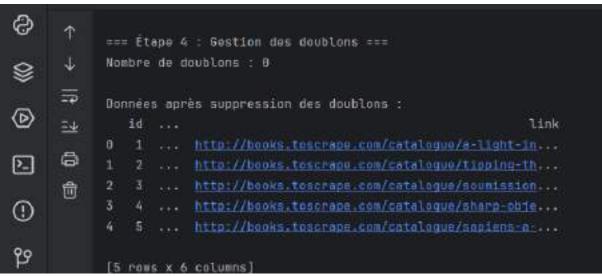
Format Attendu du Fichier CSV

Le fichier CSV doit contenir les colonnes suivantes :

- **titre** : Titre du livre (obligatoire)
- **prix** : Prix du livre au format décimal (ex. "9.99") (obligatoire)
- **categorie** : Catégorie du livre, normalisée avec une majuscule au début (obligatoire)
- **disponibilite** : Doit être "En stock" ou "Rupture de stock" (obligatoire)
- **note** : Note du livre, exprimée en entier (1 à 5) ou en texte ("un", "deux", etc.) qui sera converti (obligatoire)
- **lien** : Lien vers le livre (obligatoire)
- **description** : Description du livre (optionnel)

```
ලා
            <class 'pandas.core.frame.DataFrame'>
            RangeIndex: 120 entries, 0 to 119
            Data columns (total 6 columns):
                          Non-Null Count
                Column
                                         Dtype
Ø
               id
                         120 non-null
                                         int64
      =↓
            0
                         120 non-null
                title
                                         object
      2
               price
            2
                         120 non-null
                                         object
               category 120 non-null
            3
                                        object
      偷
①
               rating
                         120 non-null
                                         object
            5
                         120 non-null
                link
                                         object
            dtypes: int64(1), object(5)
প্ৰ
            memory usage: 5.8+ KB
Projet_Python >  connexion.py
```





```
=== Étape 5 : Ajout de colonnes calculées ===
          Moyenne des notes : 2.85
          Données avec colonnes calculées :
                ... price_category
     囨
              1
          0
                        Très cher
              2
                        Très cher
          1
     面
          2
              3
                        Très cher
◑
          3
                            Cher
          4
              5
                        Très cher
প্ৰ
```

Nettoyer la colonne 'prix'

```
# Nettager to colone 'prix

[lives['prix'] = lives['prix'] str.replace('holdstr, '', bug@lffstss) = lappriser to remote E

[lives['prix'] = lives['prix'].str.replace(',',',',', lappriser) # Separager is: sirgulas per des prixis

[lives['prix'] = pd.tn.reperis[lives['prix'], become="topers') # [smootin es mindre sicise]

# VMclfist tos selaces surguentes apres conversion
```

Vérifier les valeurs manquantes après conversion

```
# Vérifier les valeurs manquantes après conversion

if livres["prix"].isnull().any();

print("Erreur : Le colonne 'prix' contient des valeurs non numériques ou invalides.")

exit(2)
```

Remplacer les valeurs NaN par des valeurs par défaut

```
* Nerolecer Les esteurs Rais per une valeurs per détaut

'Livres = livres.fillne({
    "description": ""    # Wemplacer Nail dans la colonne 'description' par une chaîne vide
})
```

Dictionnaire de conversion des notes

```
Nationalis de consectamente motos

mapping_notos = {
    "un": 1, "dese": 2, "trusa": 3, "santre": 4, "sang": 5,
    "une": 1, "trus": 2, "trusa": 3, "trus": 4, "trus": 5 d' dese mont l'anglain el lectio
```

Convertir les notes en minuscules puis en nombres

```
fi a movemble les notes en minascules nus en nonpres
livres['note'] - livres['note'].str.lower().map(mapping_notes)
```

Vérifier si des notes n'ont pas été converties

```
If lives['note'] landliD may();

print['Error : Loctains notes continuent (or volumes incomment ', lives['note'] ani(os())

satt(t)
```

Normaliser les catégories

Calculer la moyenne des avis

```
# Wormsliser its categories

Livres["categorie"] = Livres["categorie"].str.strip().str.cepitalize()

# Eachtier is myones del will

# moyenne_avis = Livres["note"].meen()

Livres["moyenne_avis"] = myonne_evis
```

Fonction pour vérifier les contraintes

```
The security of the security o
```

Appliquer la vérification

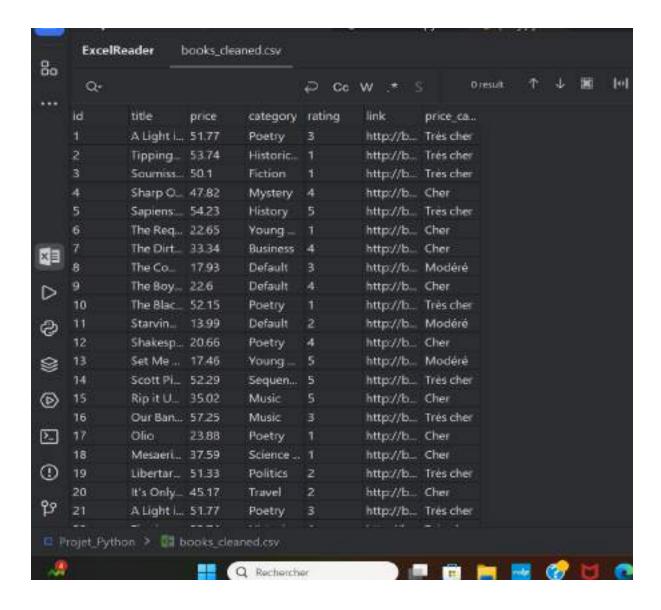
Préparation des données pour l'insertion

Insertion des données

```
[5 rows x 7 columns]

Données nettoyées seuvegardées dans 'books_cleaned.csv'.

Process finished with exit code 8
```

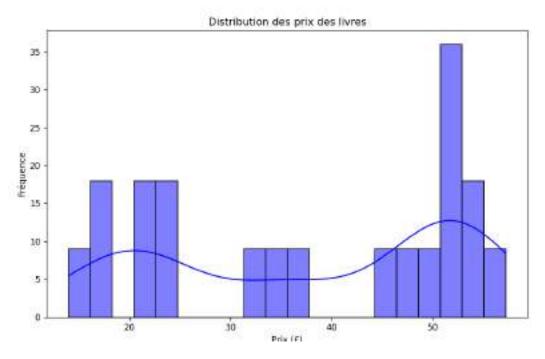


ANALYSES STATISTIQUES ET VISUALISATIONS

Distribution des notes

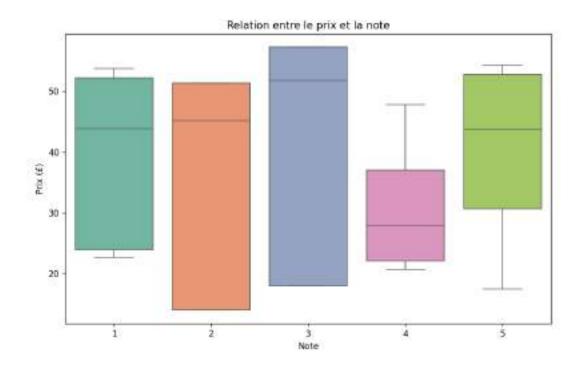
```
print("\n=== ANALYSES STATISTIQUES ET VISUALISATIONS ===")

# 1. Distribution des prix
plt.figure(figsize=(10, 6))
sns.histplot(df['price'], bins=20, kde=True, color='blue')
plt.title('Distribution des prix des livres')
plt.xlabel('Prix (£)')
plt.ylabel('Fréquence')
plt.show()
```



3. Relation entre le prix et la note

```
185
186 # 3. Relation entre le prix et la note
187 plt.figure(figuize=(10, 6))
188 sns.boxplot(s='rating', s='prics', data=df, palette='Set2')
189 plt.title('Relation entre le prix et la note')
190 plt.xlabel('Note')
191 plt.ylabel('Prix (E)')
193 plt.show()
193
```



Explorer la relation entre le prix des livres et leurs notes.

```
# Distribution des notes

plt.figure(Figuire=(8, 5))

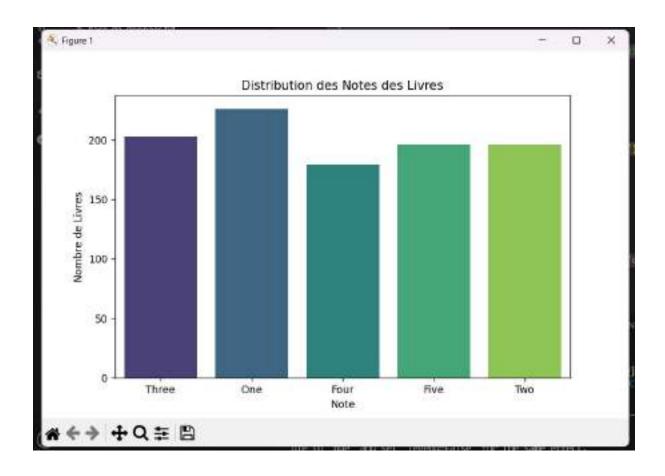
sns.countplot(xz"note", fint==livres, paleite="viridis")

plt.title("Distribution des Notes des Livres")

plt.xlabel("Note")

plt.ylabel("Nombre de Livres")

plt.show()
```



Corrélation entre le prix et la note

```
plt.figure(figure=(16, 6))
sns.scatterplot(a="prix", p="note", Mate=livres, None"categorie", notette="Set7")
plt.title("Correlation entre le Prie et la Note")
plt.xlobel("Prix (E)")
plt.ylobel("Note")
plt.legend(fitte="Cotegorie")
plt.show()
```

